

RNN 기반 Seq2Seq 신경망 기계번역에서

attention 메커니즘의 종류가

번역 품질 및 오류 양상에 미치는 영향을 분석

요 약

RNN기반 Seq2Seq신경망 기계 번역에서 attention메커니즘에 따른 성능 및 오류를 분석한다.

Key words

Neural Machine Translation, Seq2Seq, Attention, Alignment Visualization, Bahdanau Attention, Dot Attention, Scaled Dot Attention, Luong Local-m attention

I. 서 론

기존 RNN기반 Seq2Seq모델은 문장이 길어 질수록 정보 손실이 발생하고 이를 해결하기 위해 attention을 도입하였다.[1]

본 연구는 기존 Bahdanau Attention 모델을 기반으로 동일한 데이터 셋, 동일한 구조에서 attention을 변경하며 BLEU 점수, 번역 결과, attention heatmap을 비교한다.


표 1. 실험 방법 및 데이터 세트

실험방법	데이터 세트
데이터셋	Multi30k (영 - 독)
학습/검증/테스트	29k / 1k / 1k
Vocab 크기(영/독)	5,921 / 7,859
특수 토큰	<pad>, <sos>, <eos>, <unk>
희귀어 처리	1회 등장 단어는 <unk>
GPU	A100 40GB

II. 모델 구조 및 Attention 방법

본 연구의 baseline인 Bahdanau Attention 모델을 소개하고 동일한 데이터 셋과 구조로 attention을 dot attention, local-m attention, scaled-dot attention을 바꿔서 학습 후 실험결과를 제시한다.

II.1 Bahdanau Attention baseline 모델



Bahdanau Attention 모델은 Encoder의 Bi-RNN의 hidden state들과 Decoder hidden state를 Additive Attention으로 결합해 context를 vector를 생성하는 구조이다.

Encoder는 양방향 RNN으로 입력 문장의 각 위치 j 에 대해 forward hidden state와 backward hidden state를 계산한 뒤 연결하여 annotation

hidden state를 생성한다.

$$h_j = [h_j^{\rightarrow}; h_j^{\leftarrow}]$$

Decoder는 이전 단어와 이전 은닉 상태, attention으로 계산된 context vector를 이용하여 은닉 상태를 갱신하고 다음 단어의 확률을 출력한다. $p(y_i|y_1, \dots, y_{i-1}, x) = g(y_{i-1}, s_i, c_i)$

additive attention을 적용한 계산 과정은 다음과 같다.

1) Alignment score

$$e_{ij} = v_a^T \tanh(W_s s_{i-1} + W_h h_j)$$

2) Attention weight

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})}$$

3) Context vector

$$c_i = \sum_{j=1}^{T_x} \alpha_{ij} h_j$$

[1]

II.2 Dot Attention 모델

Dot Attention은 Decoder의 이전 은닉 상태와 Encoder의 annotation hidden state의 내적으로 score를 계산한다.

$$e_{ij} = s_{i-1}^T h_j \quad [2]$$

II.3 Local Attention 모델(Local-m)

Local Attention은 각 타겟 시점 l에 대해 전체를 보지 않고 정렬 중심 위치, 즉 주변의 작은 window에 대해서만 attention을 계산한다.

Local-m은 정렬 위치 p를 단순히 현재 위치 l로 설정한다.

II.4 Scaled Dot-Product Attention

Scaled dot-product attention은 dot-product score를 $\sqrt{d}$ 로 나누어 softmax를 안정화해 attention의 분포가 한 위치로 몰리는 현상을 완화한다. [3]

III. 실험 및 결과 분석

III.1 실험 설계

본 연구는 attention 메커니즘의 차이가 번역 품질 및 정렬 특성에 미치는 영향을 분석하기 위해 attention 모듈을 제외한 모든 조건을 동일하게 통제하였다.

III.2 정량 결과 분석(BLEU 점수 비교)

모델	BLEU
Bahdanau (Baseline)	29.17
Dot	24.07
Local-m	25.78
Scaled Dot	29.30

실험 결과

모델	BLEU
Bahdanau (Baseline)	21.50
Dot	18.60
Local-m	18.60

baseline 논문 결과

BLEU 점수는

ScaledDot(29.30) > Bahdanau(29.17) > > Local(25.78) > Dot(24.07) 순으로 나타났으며 baseline 논문 결과에 비해 BLEU 점수가 잘 나온 이유는 본 연구의 데이터셋은 Multi30k로 baseline의 데이터셋인 WMT14보다 쉬운 문장으로 구성된 것이 원인인 것으로 추정된다.

Bahdanau가 Dot, local-m보다 점수가 더 높으며 Dot과 local-m은 차이가 별로 나지 않는 것은 baseline논문의 결과와 유사하게 나온다.


baseline 논문에서 추가로 실험해본 scaled-dot attention의 경우 기존 Bahdanau보다 점수가 더 높게 나오는 것으로 관찰되었다.

기존 dot에서 softmax를 안정화 시켜 더 많은 영역을 보도록 한 것이 BLEU 점수를 5.23점이나 향상 시킨 것으로 softmax의 안정화가 번역에 있어서 성능에 유의미한 결과를 보이는 것을 확인하였다.

III.3 정량 결과 분석(번역, attention heatmap)

[예문 1]

항목	문장
Source(EN)	a man in an orange hat starring at something .
Target(DE)	ein mann mit einem orangefarbenen hut , der etwas anstarrt .
Bahdanau	ein mann mit einem orangefarbenen begutachtet begutachtetetwas etwas an .
Dot	ein mann mit einem orangefarbenen hut betrachtet etwas etwas .
Local-m	ein mann mit einem orangefarbenen schutzhelm betrachtet etwas
Scaled Dot	ein mann mit orangefarbener mütze starrt auf etwas etwas .




Bahdanau와 Dot/Scaled Dot에서 반복 생성이 관찰되었으며 Local-m은 반복은 적으나 명사 hut→schutzhelm처럼 명사 오번역이 발생하였다.

heatmap의 경우 Bahdanau보다 Scaled Dot이 후반에 정렬의 유지가 더 나은 양상을 보였지만 반복의 개수만 줄어든뿐 여전히 반복은 발생하였다.

local-m의 경우 자신의 위치에서 관찰 한다는 특성상 대각선을 유지하지만 한번 잘못 특정할 경우 크게 정렬이 크게 틀어지는 모습을 보였다.

[예문 2]

항목	문장
Source(EN)	a boston terrier is running on lush green grass in front of a white fence .
Target(DE)	ein boston terrier läuft über saftig-grünes gras vor einem weißen zaun .
Bahdanau	ein <unk> rennt auf einem grünen wiese vor einem weißen zaun .
Dot	ein <unk> rennt läuft vor einem weißen vor einem weißen zaun .
Local-m	ein <unk> läuft auf einem grünen gras vor einem weißen <unk>.
Scaled Dot	ein <unk> rennt auf einer grünen gras vor einem weißen zaun .




모든 모델에서 boston terrier가 <unk>으로 출력되는 것을 확인 할 수 있었다.

local-m의 경우 다른 attention과 비교하여 제일 올바른 정렬이 나타난 것을 확인 할 수 있다.

모든 모델에서 표현력은 떨어지지만 의미는 유지한 것을 확인 할 수 있었다.

[예문 3]


항목	문장
Source(EN)	a girl in karate uniform breaking a stick with a front kick .
Target(DE)	ein mädchen in einem karateanzug bricht ein brett mit einem tritt .
Bahdanau	ein mädchen in <unk> schlägt einen stock mit einem fußtritt . .
Dot	ein mädchen gekleidetes mädchen macht einen stock mit einem <unk> . .
Local-m	ein mädchen in uniform kleidung einen einen stock mit einem
Scaled Dot	ein mädchen in karateanzug kostümen einen stock mit einem korb . .



모든 모델에서 karate 관련 표현이 <unk>또는 비관련 언어로 대체된 것을 확인하였다.

[예문 4]

항목	문장
Source(EN)	five people wearing winter jackets and helmets stand in the snow , with snowmobiles in the background .
Target(DE)	fünf leute in winterjacken und mit helmen stehen im schnee mit schneemobilen im hintergrund .
Bahdanau	fünf personen in jacken und mit stehen im schnee . im im im im hintergrund .
Dot	fünf personen mit helmen und helm stehen im im im im hintergrund .
Local-m	fünf personen in winterkleidung und mit helmen stehen im im schnee , im hintergrund hintergrund
Scaled Dot	fünf personen mit mit jacken und helmen stehen im schnee und im hintergrund im hintergrund . .



모든 모델에서 긴 문장 후반부에 반복이 증가하는 것을 확인하였다.

local-m을 제외한 다른 3개의 attention은 문장 후반부에 heatmap이 수직으로 떨어지는 경향을 보인다.

대각선의 정렬을 유지한 local-m attention의 경우 다른 모델보다 반복이 덜 일어난 것을 확인하였다.

IV. 결 론

본 연구는 Bahdanau attention모델을 기반으로 attention 메커니즘의 종류가 번역 품질 및 오류 양상에 미치는 영향을 분석하였다.

동일한 데이터셋, 구조를 기반으로 attention 모듈을 변경하였을 때 baseline비해 유의미한 성능 차이는 발생하지 않았으며 번역 품질의 개선보다는 오류의 양상이 변화하는 것이 관찰되었다. 또한 모든 모델에서 문장의 후반부로 갈수록 의미손실, 반복 등의 오류가 공통적으로 나타나는 RNN기반 모델의 한계를 관찰 할 수 있었다.

향후 연구로는 Transformer기반 self-attention의 번역 품질 및 오류 양상을 확인해 볼 수 있으며 어순 차이가 큰 언어쌍(EN-KOR)으로 확장하여 어순 차이에 따른 정렬 특성 변화를 분석하는 방향을 제안한다.

V. 부 록

참고 github주소

<https://github.com/Maab-Nimir/Neural-Machine-Translation-by-Jointly-Learning-to-Align-and-Translate>

프로젝트 코드

https://github.com/seokhwan01/cv_project

데이터셋

<https://github.com/Multi30k/dataset>

한글제목	휴먼명조, 17, 장평:90, 자간: -7
저자명	돈움, 11, 장평:90, 자간: 5
영문제목	견명조, 15, 장평:90, 자간: -7
영문저자명	휴먼명조, 10, 장평:90, 자간: 5
요약본문	휴먼명조, 9.2, 장평:90, 자간:-6
영문요약문	영문:Times New Roman, 9.2, 장평:90, 자간:-6
각장제목	휴먼고딕, 11, 장평:90, 자간:-6
본문내용	휴먼명조, 10, 장평:90, 자간:-6
소제목	중고딕 11, 장평:90, 자간:-6
그림캡션	중고딕, 9, 장평:90, 자간:-6
표캡션	중고딕, 9, 장평:90, 자간:-6
식	크기 9, 원정렬, 식번호는 오른 정렬
참고문헌	영문:Times New Roman, 10, 장평:90, 자간:-6

참 고 문 헌

- [1] D. Bahdanau, K. Cho, and Y. Bengio, “Neural Machine Translation by Jointly Learning to Align and Translate,” Proc. of International Conference on Learning Representations (ICLR), 2015.
- [2] M.-T. Luong, H. Pham, and C. D. Manning, “Effective Approaches to Attention-based Neural Machine Translation,” Proc. of Conference on Empirical Methods in Natural Language Processing (EMNLP), 2015.
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention Is All You Need,” Proc. of Advances in Neural Information Processing Systems (NeurIPS), 2017.